

Models

12 종 모델 선택과 라우팅

Claude, DeepSeek, MiniMax, GLM, Qwen, Auto router

Context window, cost multiplier, use case별 권장 모델

Choi, WooHyung

Prin. Solutions Architect

AWS Korea

whchoi@amazon.com



Agenda

Chapter 04, Models

- 01 13 개 모델 전체 비교표
Context, cost, region, 구독 등급별 사용 가능 여부
- 02 Claude Opus 시리즈
Opus 4.7 / 4.6 / 4.5, 가장 강력한 reasoning
- 03 Claude Sonnet 과 Haiku
Sonnet 4.0 / 4.5 / 4.6, Haiku 4.5, Auto router
- 04 비 Claude 모델 4 종
DeepSeek, MiniMax, GLM, Qwen, 비용 최적화
- 05 Use case 별 권장 모델
8 가지 시나리오, 작업 종류 + 비용 효율
- 06 모델 전환 방법
/model, settings, set-current-as-default
- 07 모델 행동 차이와 베스트
Planning, adaptive thinking, self-correction

13 개 모델 전체 비교표

CONTEXT, COST, AND AVAILABILITY

Model	Context	Cost	Region	Free Tier
Claude Opus 4.7	1M	2.2x	us-east-1, eu-central-1	Pro+
Claude Opus 4.6	1M	2.2x	us-east-1, eu-central-1	Pro+
Claude Opus 4.5	200K	2.2x	us-east-1, eu-central-1	Pro+
Claude Sonnet 4.6	1M	1.3x	us-east-1, eu-central-1	Pro+
Claude Sonnet 4.5	200K	1.3x	us-east-1, eu-central-1	Free
Claude Sonnet 4.0	200K	1.3x	us-east-1, eu-central-1	Free
Auto (router)	Mixed	1.0x	us-east-1, eu-central-1	Free
Claude Haiku 4.5	200K	0.4x	us-east-1, eu-central-1	Pro+
MiniMax M2.5	200K	0.25x	us-east-1, eu-central-1	Free
GLM-5	200K	0.5x	us-east-1	Free
DeepSeek 3.2	128K	0.25x	us-east-1	Free
MiniMax M2.1	200K	0.15x	us-east-1, eu-central-1	Free
Qwen3 Coder Next	256K	0.05x	us-east-1, eu-central-1	Free

13 개

전체 모델 수

0.05 ~ 2.2x

비용 배수 범위

1M

최대 context window

Auto

추천 진입점

Claude Opus 시리즈

ANTHROPIC FRONTIER MODELS

OPUS LINEUP

Anthropic 의 가장 강력한 모델 라인. 큰 코드베이스, 복잡한 multi-system 문제, 그리고 자기 검증이 중요한 작업에 적합.
모두 2.2x cost multiplier 로 가장 비싸지만, 어려운 문제에서 정답률이 가장 높음.

OPUS 4.7

Adaptive thinking

최신 모델, 작업 복잡도에 따라
reasoning 깊이 자동 조절.
Self-verification 과 3x 고해상도 vision
지원. (2026 년 4 월 출시)

OPUS 4.6

대규모 codebase planning

Terminal-Bench 2.0 과 SWE-bench
Verified 최고 점수.
수백만 line codebase 의 planning 과
self-correction 이 강함.

OPUS 4.5

복잡한 multi-system

Tradeoff 와 ambiguity 처리
강한 단일 시도 정확도.
여러 시스템 경계를 가로지르는 SW 챌린
지에 적합.

2.2x

공통 cost multiplier

1M

Opus 4.7, 4.6 context

200K

Opus 4.5 context

Adaptive

Opus 4.7 신규 기능

Claude Sonnet, Haiku, Auto

BALANCED AND FAST OPTIONS

AUTO

추천 진입점

Kiro 의 자동 model router.
작업별 최적 모델 자동 선택.
Sonnet 4 급 품질을 1.0x 비용으로 제공.
일반 개발에 가장 권장.

SONNET 4.6

효율적 고지능

Sonnet 4.5 + Opus 급 지능, token 효율 우수.
1M context, 1.3x cost.
반복적 개발과 long session 에 강함.

SONNET 4.5

강한 agentic coding

Sonnet 4.0 + 향상된 planning, 확장된 자율 동작.
200K context, 1.3x cost.
도구 사용 능력이 우수.

HAIKU 4.5

속도와 비용 절감

Sonnet 4 급 reasoning, 2 배 빠른 속도, 1/3 비용.
0.4x cost multiplier.
빠른 반복과 subagent orchestration 에 적합.

1.0x

Auto 기본 비용

1.3x

Sonnet 계열 비용

0.4x

Haiku 비용

Auto

권장 시작 모델

비 Claude 모델 4 종

OPEN-WEIGHT COST-OPTIMIZED OPTIONS

MINIMAX M2.5

Frontier 급 low cost

Open weight, Opus 급 코딩
성능, 0.25x cost. 수십만
real-world 환경에서 RL 훈련
. 200K context
us-east-1 과 eu-central-1.

GLM-5

Repo-scale agentic

Open weight sparse
MoE, 200K context,
0.5x cost.
대형 codebase 의 cross-
file migration 과 full-
stack 작업에 강함.

DEEPSEEK 3.2

최소 비용 코딩

Open weight, 128K
context, 0.25x cost.
Long tool-calling chain
과 stateful session 의
multi-step reasoning 에
적합.

QWEN3 CODER

가장 저렴한 선택

Open weight, 256K
context, 0.05x cost.
Long agentic session 의
error recovery 가 강함.
Kiro 에서 가장 cost-
effective 모델.

0.05x

최저 cost, Qwen3

256K

최대 context, Qwen3

Open

Open weight 모델들

us-east

공통 지원 리전

Use case 별 권장 모델

WHICH MODEL FOR WHICH JOB

Use case	권장 모델	이유
일반 개발	Auto	작업별 최적 모델 자동 라우팅
일관된 baseline	Sonnet 4.0	라우팅 없음, 항상 동일 모델
강한 agentic coding	Sonnet 4.5	확장된 자율 동작, 도구 사용 강화
효율적 고지능	Sonnet 4.6	Opus 급 지능, token 효율
대형 codebase	Opus 4.7 / 4.6	Long context, self-verification
속도와 비용 절감	Haiku 4.5	Sonnet 4 급, 2 배 빠름, 1/3 비용
최소 비용	Qwen3 Coder	0.05x cost, 256K context
다국어 프로그래밍	MiniMax M2.1	Rust, Go, C++, Kotlin, TS 등

8 가지

주요 use case

Auto

기본 권장

Opus

최고 난이도용

Qwen3

최저 비용용

모델 전환 방법

SWITCHING AND DEFAULTS

MODEL SWITCHING

세션 내에서 slash command 로 즉시 전환, settings 명령으로 영구 default 설정

현재 모델을 default 로 저장하는 세 가지 방법 지원, 설정은 ~/.kiro/settings/cli.json 에 저장.

/MODEL

세션 내 즉시 전환

Chat 세션 중에 /model 입력.
드롭다운에서 선택.
현재 세션에만 적용되며 새 세션은
default 사용.

SETTINGS

Default 영구 설정

kiro-cli settings chat.defaultModel <모델명>
모든 새 세션에 자동 적용.

SET-CURRENT

현재 모델을 default 로

/model set-current-as-default
지금 사용 중인 모델을 default 로 즉시
저장하는 단축 명령.

/model

세션 내 전환

settings

영구 default

set-current

현재값 저장

cli.json

저장 파일명

모델 행동 차이와 베스트 프랙티스

HOW MODELS BEHAVE DIFFERENTLY

BEHAVIORAL DIFFERENCES

모델별 행동 특성

1. Planning 깊이 - Opus > Sonnet > Haiku
2. Adaptive thinking - Opus 4.7 만 지원
3. Self-correction - Opus 계열이 강함
4. Session 지속력 - Opus > Sonnet > Haiku
5. Initiative - Opus 가 더 적극 변경

BEST PRACTICES

사용 권장 사항

1. Auto 로 시작 - 일반 작업 대부분 OK
2. 막힐 때 Opus 로 전환
3. 빠른 iteration 은 Haiku
4. 사용량을 settings 에서 모니터링
5. Opus 주력이면 Pro+ 또는 Power

5 가지

행동 특성 차이

Adaptive

Opus 4.7 단독

Auto first

기본 권장 전략

Pro+

Opus 주력 등급

Thank you!

Choi, WooHyung / Prin. Solutions Architect / AWS Korea

whchoi@amazon.com

<https://linkedin.com/in/woohyungchoi>

© 2026, Amazon Web Services, Inc. or its affiliates. All rights reserved. Amazon Confidential and Trademark.

